EMat Escuela de Matemática

Universidad de Costa Rica

Departamento de Ciencias Actuariales

MA0501 Análisis Numérico

Proyecto de investigación:

Estimación y regularización de matrices de dependencia mediante Teoría de Matrices Aleatorias (RMT) entre líneas de seguro del mercado costarricense con datos de SUGESE.

Avance 1

Integrantes:

Sebastián Miranda Ramírez C4H274

Benjamín Gutiérrez Padua C4F813

Kevin David Calderón Martínez C4D511

Gabriel de Jesús Chaves Esquivel C4E273

Miguel Tovar B89795

2026

1. Motivación y planteamiento del proyecto

1.1. ¿Cómo se relacionan las líneas de seguro?

La tesis de Chen (2025) es la referencia principal que inspiró este proyecto. Su aplicación de la teoría de matrices aleatorias a las razones de siniestralidad y a las redes de riesgo en seguros nos llevó a explorar esas relaciones en el mercado costarricense con datos de SUGESE.

Estudiar cada serie de siniestralidad por separado permite conocer su nivel habitual, cuánto varía y en qué períodos aumentan los siniestros respecto de las primas. En este proyecto nos interesa también cómo se mueven unas series respecto de otras. Dos carteras con promedios distintos pueden subir al mismo tiempo, mientras que otras con niveles parecidos pueden moverse en sentidos opuestos.

Trabajamos con datos públicos de primas y siniestros de SUGESE. Cada combinación de aseguradora y ramo es un *nodo*, identificado por $i = (a, r)$. Así podemos comparar ramos de una misma empresa y aseguradoras que operan en un mismo ramo, sin resumir toda la actividad de cada compañía en una sola serie.

La pregunta es si hay grupos de nodos que tienden a moverse juntos y cuánto de esa relación puede deberse a tener pocas observaciones. Conocer estas asociaciones puede ayudar a estudiar la diversificación, la concentración de exposiciones y las necesidades de reaseguro, además de describir qué partes del mercado tienen comportamientos relacionados. Para llevar esos resultados a decisiones económicas haría falta más información sobre las carteras.

1.2. El indicador y las correlaciones

Para cada nodo i y período t, calculamos la razón entre siniestros brutos S_{it} y primas brutas P_{it}:

$$L_{it} = \frac{S_{it}}{P_{it}}, \qquad P_{it} \neq 0.$$

Los montos originales son acumulados dentro del año, por lo que primero los convertimos en flujos trimestrales. Esta razón mide siniestros por unidad de prima cuando las primas son positivas y las partidas son comparables; no es directamente el índice técnico neto de siniestralidad. Los valores negativos, las primas cercanas a cero y las observaciones extremas quedan sujetos a revisión porque pueden alterar bastante el cociente y sus correlaciones.

Organizamos los datos en una matriz $L \in \mathbb{R}^{N \times T}$, con un nodo por fila y un período por columna. Después centramos cada fila y la dividimos por su desviación estándar muestral. Esto permite comparar fluctuaciones entre series con distintos niveles y dispersiones, siempre que tengan varianza positiva y datos en los mismos períodos.

La correlación de Pearson mide la asociación lineal entre dos series. En términos poblacionales,

$$\rho_{ij} = \frac{\operatorname{Cov}(L_i, L_j)}{\sqrt{\operatorname{Var}(L_i)\operatorname{Var}(L_j)}}.$$

Una correlación positiva indica que ambas tienden a desviarse de su media en el mismo sentido; una negativa, en sentidos opuestos. La matriz reúne esas relaciones para todos los pares. Es simétrica, así que no indica una dirección de transmisión: una correlación alta no demuestra contagio y una cercana a cero no descarta relaciones no lineales.

1.3. De la matriz a los grafos y los grupos

Para leer la matriz como una red, usamos los pares aseguradora–ramo como nodos y sus correlaciones como enlaces. En este avance probamos dos formas de seleccionar esos enlaces: una red *signed* por umbral, que conserva correlaciones positivas y negativas suficientemente fuertes, y dos versiones del PMFG, que agregan conexiones mientras la red siga siendo planar.

El umbral facilita la comparación visual, pero exige la misma magnitud a todas las relaciones. Por eso puede dejar fuera un grupo con correlaciones moderadas aunque sus nodos estén más relacionados entre sí que con el resto. Además, cambiar el umbral cambia la red, aun cuando los datos sean los mismos. El árbol de expansión mínima es otra opción: conecta todos los nodos con $N - 1$ enlaces y sin ciclos, pero descarta muchas relaciones para mantener esa estructura.

Estas representaciones ayudan a explorar conexiones. Para buscar grupos necesitamos además un criterio que compare las relaciones internas con las externas. MacMahon y Garlaschelli (2015) distinguen este problema del filtrado de enlaces y proponen una modularidad adaptada a matrices de correlación.

También importa el período elegido. Una matriz calculada con toda la muestra puede mezclar etapas con relaciones distintas y no equivale, en general, a promediar las correlaciones de esas etapas. Revisar la estabilidad temporal sigue siendo parte del trabajo; el filtrado espectral no resuelve ese punto por sí solo.

1.4. ¿Dónde entra la teoría de matrices aleatorias?

Con una muestra finita aparecen correlaciones distintas de cero incluso entre series independientes. El problema se hace más evidente cuando hay muchas series y pocos períodos. La teoría de matrices aleatorias (RMT) permite comparar los valores propios de la matriz empírica con una referencia de lo que esperaríamos por ruido muestral, bajo supuestos de independencia y estructura temporal.

Los valores propios indican cuánta variación corresponde a cada dirección de movimiento conjunto, descrita por su vector propio. Los modos que superan la referencia se conservan como candidatos a señal. Esa selección depende del modelo nulo: no garantiza que todo lo descartado sea ruido ni da una explicación económica a lo retenido.

La señal puede incluir tanto movimientos generales como patrones de grupos. Las variantes de modularidad de MacMahon y Garlaschelli descuentan el ruido y, en una de ellas, también un modo global. Para interpretar el modo principal como un movimiento general del mercado hay que revisar las cargas de su vector propio y su estabilidad, además de su valor propio.

La parte numérica del proyecto consiste en construir la matriz, calcular sus valores y vectores propios, reconstruir las componentes filtradas y estudiar las particiones que se obtienen. En este avance presentamos los primeros resultados sobre el panel actual.

2. Hallazgos del proyecto

2.1. Análisis exploratorio

El panel contiene 50 series y 32 trimestres, de 2015 a 2022: 1600 observaciones en total. Los gráficos de cambios trimestrales y anuales muestran oscilaciones recurrentes en Automóvil y en el seguro obligatorio de riesgos del trabajo (SRT), además de movimientos abruptos en Caución y en el seguro obligatorio de automóviles (SOA). Los cambios mensuales quedan pendientes.

La media de las razones individuales es 0,6408 y la mediana es 0,3269. Para comparar ramos, sumamos los siniestros y las primas entre aseguradoras en cada trimestre, calculamos su cociente y luego resumimos los valores a lo largo del tiempo.

SOA destaca con una media de 6,1891 y una mediana de 4,2280. Son valores altos, y la diferencia entre ambos sugiere revisar las observaciones que elevan el promedio. También hay valores negativos en el panel. Antes de explicar estos resultados en términos económicos, falta revisar los registros y los denominadores.

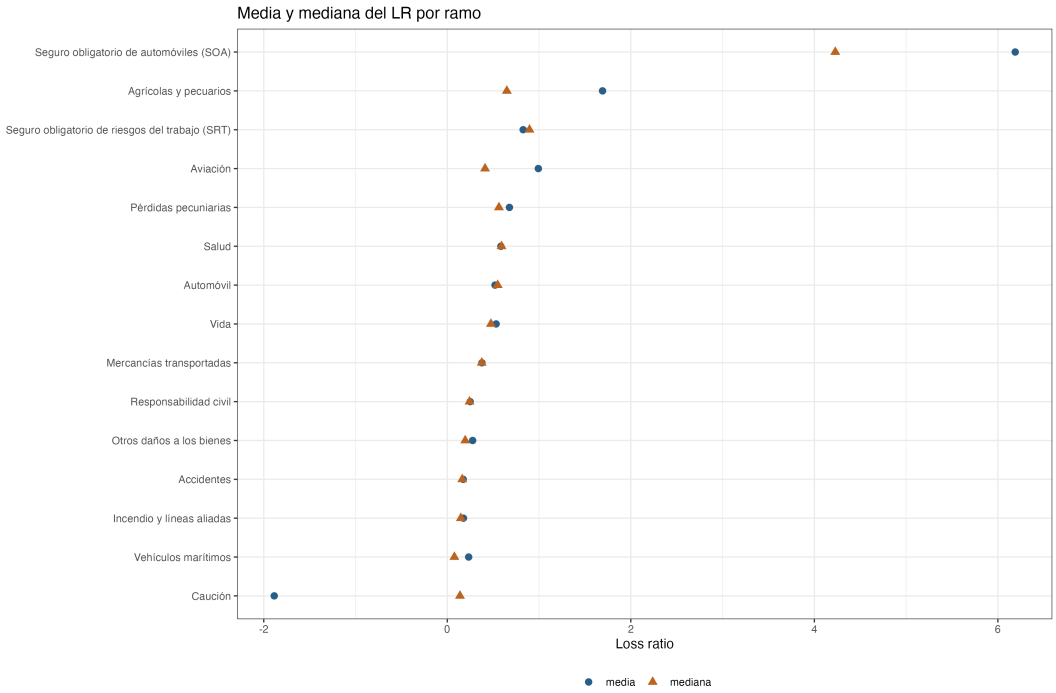


Figura 1: Media y mediana temporal de la razón agregada por ramo, 2015–2022. Los valores están en unidades, no en porcentajes.

2.2. Matriz de correlación empírica

Construimos $L \in \mathbb{R}^{50\times 32}$ y estandarizamos cada fila con su media $\bar{L}_i$ y su desviación estándar muestral s_i. Con $T = 32$,

$$X_{it} = \frac{L_{it} - \bar{L}_i}{s_i}, \qquad C = \frac{XX^{\mathsf{T}}}{T-1}, \qquad C_{ij} = \frac{1}{T-1}\sum_{t=1}^{T} X_{it}X_{jt}.$$

La matriz resultante es simétrica y tiene unos en la diagonal. En la figura ordenamos los nodos por similitud para facilitar la lectura; ese orden todavía no es una clasificación en comunidades.

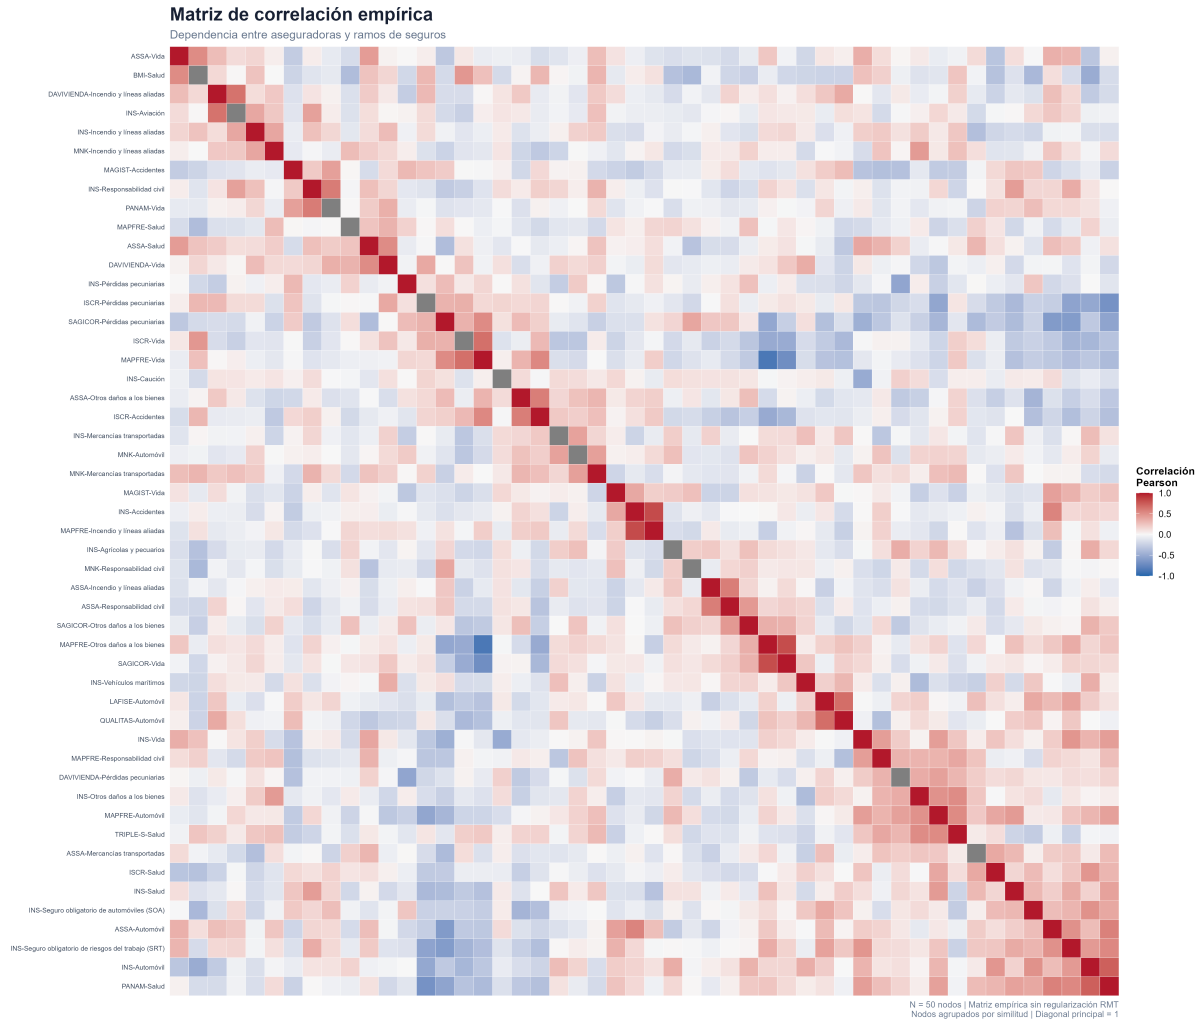


Figura 2: Correlaciones empíricas entre los 50 nodos. Rojo indica asociación positiva; azul, negativa; blanco, valores cercanos a cero. La matriz aún no tiene filtrado RMT.

Entre los 1225 pares distintos, la correlación media es 0,0114 y la mediana es 0,0009. Aun así, hay relaciones fuertes de ambos signos. Por ejemplo, INS–Accidentes y MAPFRE–Incendio y líneas aliadas tienen una correlación de 0,8237, mientras que MAPFRE–Otros daños a los bienes y MAPFRE–Vida tienen una de $-0{,}8665$. El promedio cercano a cero mezcla relaciones positivas y negativas; no significa que las series sean independientes. Falta revisar cuánto cambian estas asociaciones al variar el período o el tratamiento de los extremos.

2.3. Red signed por umbral

En esta red conservamos un enlace entre nodos distintos cuando $|C_{ij}| \geq h$. El peso sigue siendo C_{ij}, con su signo original. Así mantenemos en una misma figura las series que se mueven juntas y las que se mueven en sentidos opuestos. Usamos tres umbrales para comparar cuántas conexiones quedan:

Umbral h	Enlaces	Positivos	Negativos
0,30	161	94	67
0,40	68	42	26
0,50	32	18	14

Al pasar de 0,30 a 0,50, la red pierde 129 enlaces. En los tres casos mantenemos los 50 nodos, incluidos los que quedan aislados, y usamos las mismas posiciones para poder comparar las figuras. Estos umbrales son elecciones descriptivas, no niveles de significancia estadística.

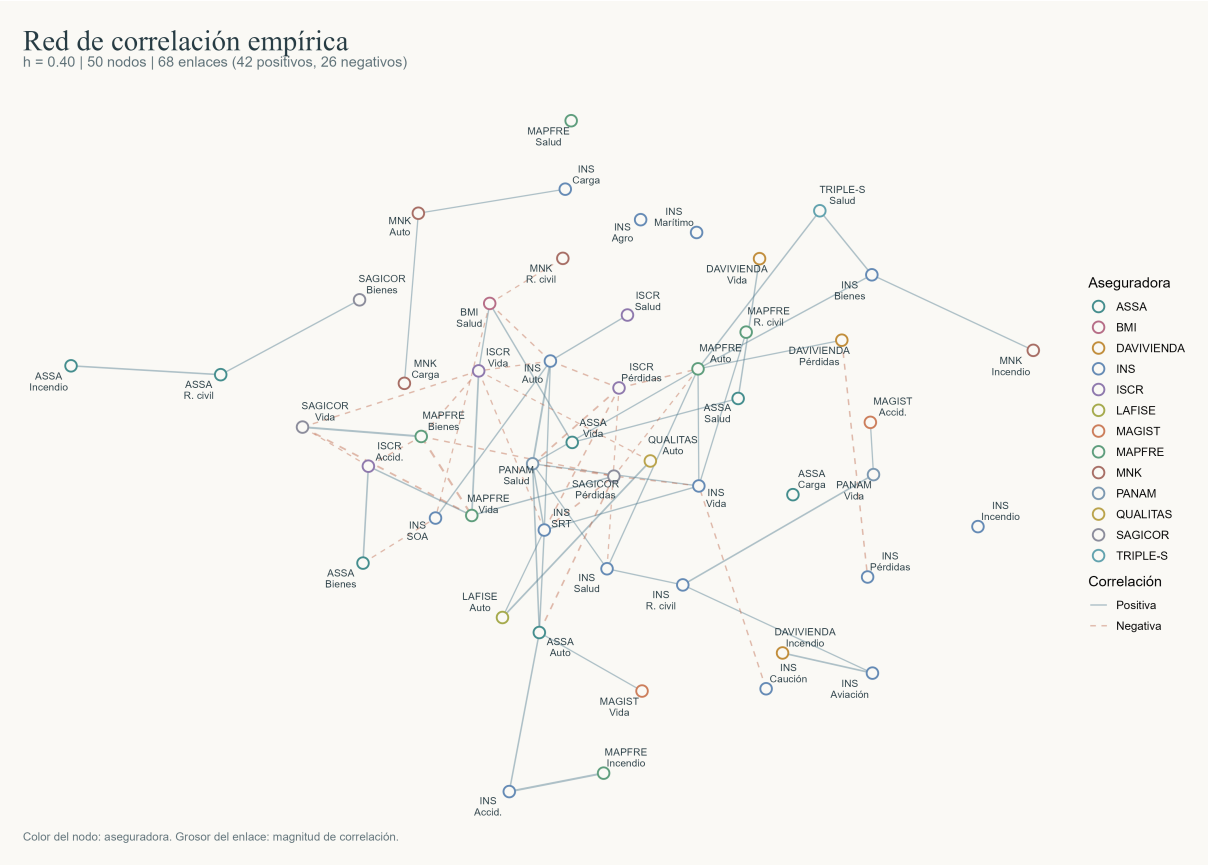


Figura 3: Red signed con $h = 0{,}40$. El color de cada nodo identifica la aseguradora. Los enlaces azules continuos son positivos y los naranjas discontinuos son negativos; el grosor indica la magnitud de la correlación.

La figura intermedia conserva 68 conexiones, de las cuales 26 son negativas. Ignorar el signo dejaría fuera una parte de las relaciones que queremos describir. Las tres redes se generan con `R/visualizar_redes.R` a partir de la matriz empírica, antes de aplicar RMT.

2.4. PMFG por correlación y por magnitud

El *Planar Maximally Filtered Graph* (PMFG) de Tumminello et al. (2005) prueba los pares en orden y acepta un enlace si la red sigue siendo planar. Comparamos el orden clásico, por C_{ij} descendente, con una adaptación por $|C_{ij}|$ descendente. Ambos conservan el signo original y alcanzan $3N - 6 = 144$ enlaces.

Criterio de orden	Positivos	Negativos	Total
Correlación C_{ij}	139	5	144
Magnitud $\|C_{ij}\|$	87	57	144

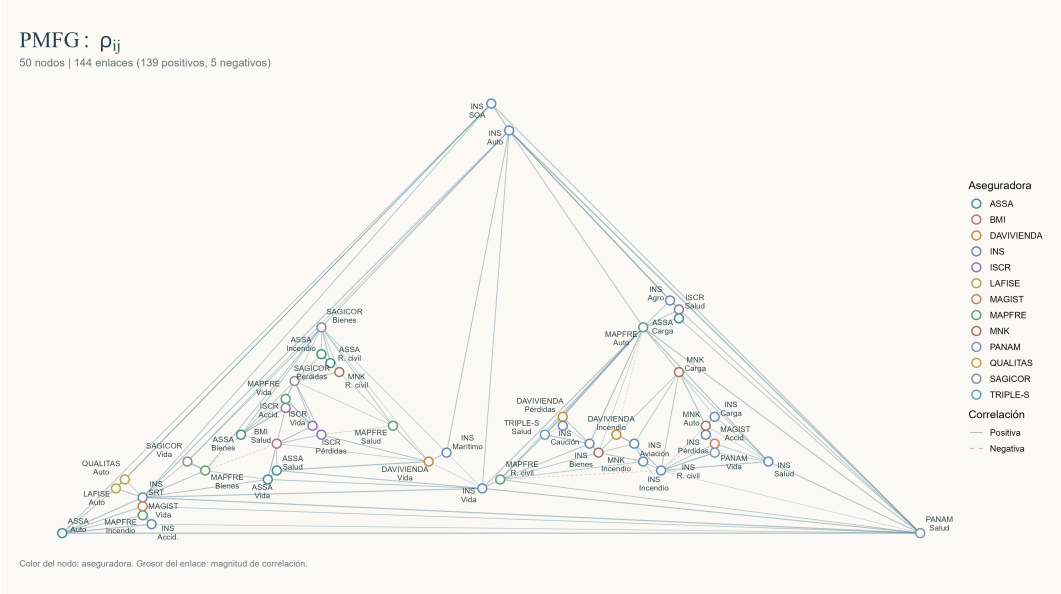


Figura 4: PMFG clásico: prioriza las correlaciones más positivas.

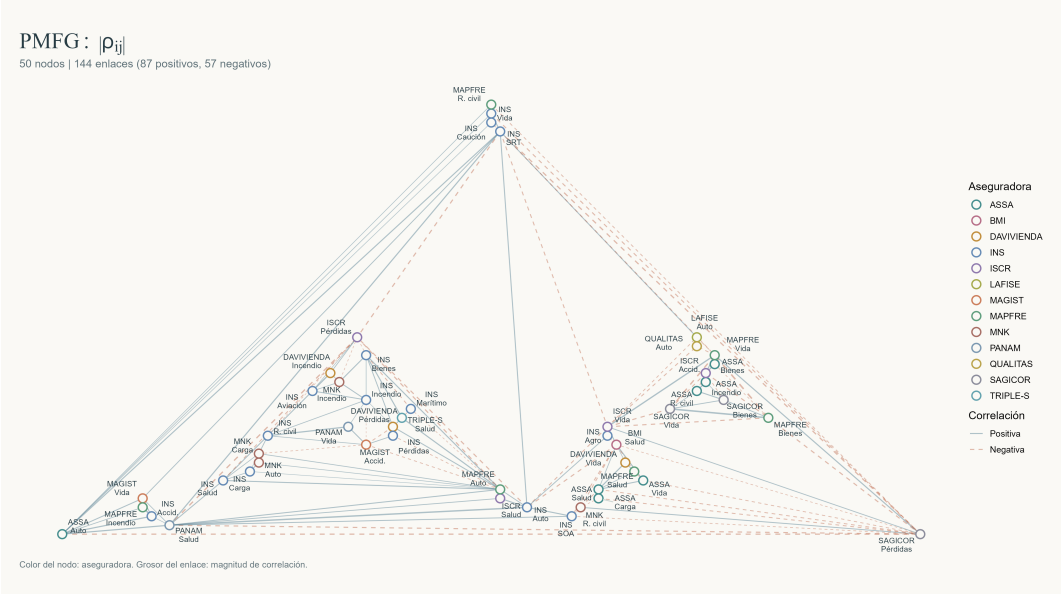


Figura 5: PMFG por magnitud: prioriza las relaciones fuertes de ambos signos.

Los PMFG comparten 75 enlaces. El de magnitud conserva la correlación de $-0{,}8665$ entre MAPFRE–Otros daños a los bienes y MAPFRE–Vida. La forma triangular viene del acomodo planar sin cruces. Estas redes seleccionan enlaces de la matriz empírica; aún no incorporan el filtro RMT.

2.5. Marchenko–Pastur y elección de modularidad

Con $N = 50$ y $T = 32$, los límites de Marchenko–Pastur (MP) son

$$q = \frac{N}{T} = 1{,}5625, \qquad \lambda_{\pm} = (1 \pm \sqrt{q})^2, \qquad [\lambda_-, \lambda_+] = [0{,}0625;\ 5{,}0625].$$

El primer valor propio es $\lambda_1 = 6{,}9270$ y el segundo es $\lambda_2 = 4{,}8250$. Solo el primero supera el límite superior y concentra el 13,85 % de la variación total. También hay un valor positivo por debajo del límite inferior (0,0553) y 19 valores prácticamente nulos. Estos últimos se explican por el rango máximo $T - 1 = 31$ de la matriz centrada; para $q > 1$, MP también incluye una masa en cero.

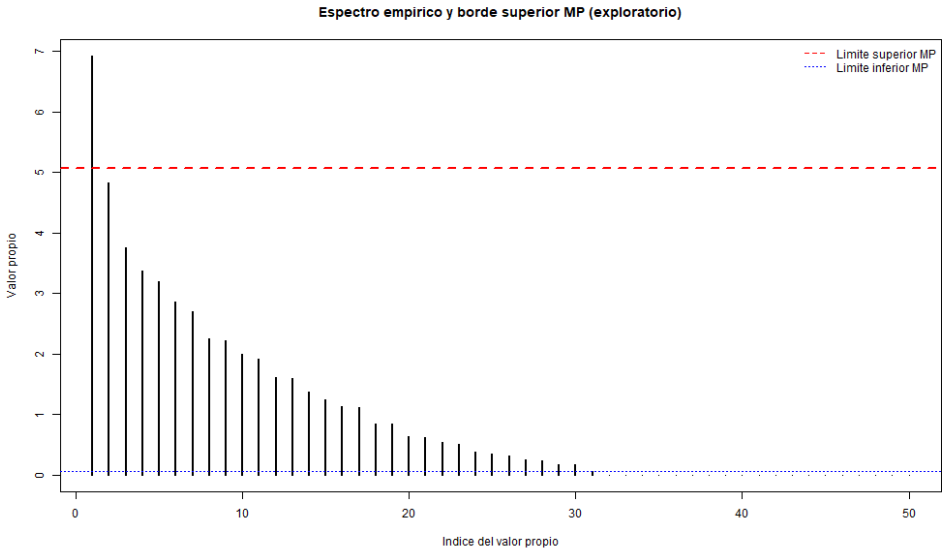


Figura 6: Espectro empírico y límites de Marchenko–Pastur. Solo la primera barra supera $\lambda_+ = 5{,}0625$.

El filtro reúne los modos con $\lambda_a \leq \lambda_+$ en $C^{(r)}$ y conserva $C^{(s)} = C - C^{(r)}$. La modularidad Q_2 de MacMahon y Garlaschelli (2015, ec. 34) usa esa señal:

$$Q_2(g) = \frac{\sum_{i,j} C^{(s)}_{ij}\, \mathbf{1}\{g_i = g_j\}}{\sum_{i,j} C_{ij}}, \qquad C^{(s)} = \lambda_1 v_1 v_1^{\mathsf{T}}.$$

Como solo conservamos un modo, retirarlo también, como hace Q_3, deja una matriz nula salvo redondeo: todas las particiones reciben el mismo valor. Por eso usamos Q_2 para distinguir particiones con el filtro actual. Q_1 se mantiene como referencia, aunque no descuenta el ruido. Con Q_2 obtenemos grupos de 33 y 17 nodos, separados por los signos del primer vector propio. Aún falta estudiar qué interpretación tienen esos grupos.

El uso de MP sigue siendo exploratorio: tenemos más series que trimestres, a diferencia del régimen $T > N$ considerado por los autores, y hay indicios de autocorrelación temporal. El siguiente paso es revisar la referencia de ruido y la sensibilidad a los extremos antes de validar las agrupaciones.

Referencias

Chen, C.-P. (2025). *The Three Studies on Applying Random Matrix Theory to Loss Ratios for General Insurance Companies*. Tesis doctoral, Departamento de Gestión de Riesgos y Seguros, National Chengchi University.

MacMahon, M. y Garlaschelli, D. (2015). *Community Detection for Correlation Matrices*. *Physical Review X*, **5**, 021006. doi:10.1103/PhysRevX.5.021006.

Tumminello, M., Aste, T., Di Matteo, T. y Mantegna, R. N. (2005). *A tool for filtering information in complex systems*. *Proceedings of the National Academy of Sciences*, **102**(30), 10421–10426. doi:10.1073/pnas.0500298102.

Repositorio del proyecto

Los datos, scripts de R y figuras del avance están en:

https://github.com/sebas-miranda/riesgo_mercado_asegurador_MA0501